Diseño de bases de datos y recolección de información

Seminario de Proyecto I (MCDI) — Unidad 4

Sergio Martín Nava Muñoz

2025-03-25

Propósito de la sesión

- Entender los **principios básicos para organizar datos** en un proyecto de investigación.
- Crear un **plan para recolectar información** de manera ordenada y ética.
- Preparar los elementos necesarios para la **Evidencia 4A** (base de datos) y presentación final.

Tip

¿Qué vamos a crear hoy?
1) Esquema de organización de datos (¿una tabla o varias?).
2) Diccionario de variables con descripción y transformaciones de cada campo.
3) Pipeline de preparación: limpieza, imputación y agregación.
4) Plan de recolección de datos.
5) Una muestra pequeña de nuestra base de datos lista para análisis.

Conexión con la sesión de pregunta de investigación

- **Pregunta general** → define qué fenómeno quieres explicar y el nivel de análisis.
- **Preguntas específicas** → delimitan dimensiones observables del problema.
- **Objetivos e hipótesis** → indican qué relaciones debes medir o contrastar.
- **Variables e indicadores** → se convierten en columnas de tu base de datos.

> **Important**
>
> En esta unidad respondemos: **"¿qué estructura de datos necesito para contestar mi pregunta de investigación con evidencia verificable?"**

Del hilo conductor a la base para análisis

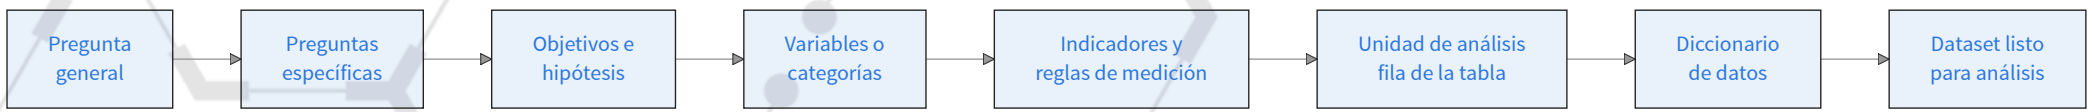

> Si no puedes ubicar una variable en este flujo, todavía no está lista para entrar a tu base.

Pasos para organizar nuestros datos

1. **Partir de la pregunta** → ¿Qué debo observar para responder mi pregunta general y específicas?
2. **Diseñar estructura** → ¿Una tabla o múltiples? ¿Qué campos necesito?
3. **Definir relaciones** → ¿Cómo se conectan los datos entre sí?
4. **Establecer reglas** → ¿Qué datos son válidos y cuáles no?
5. **Documentar todo** → Crear un diccionario que explique cada variable.
6. **Planear recolección** → ¿De dónde y cómo obtendré los datos?
7. **Transformar y preparar** → Imputar, agregar y derivar variables según tu pregunta de investigación.
8. **Verificar calidad** → ¿Cómo me aseguro de que los datos sean confiables?

De variables a organización de datos

- **Variable dependiente**: lo que quiero explicar o predecir.
- **Variables independientes**: los factores que pueden influir.
- **Variables derivadas**: nuevas variables que calculo a partir de las anteriores.

Ejemplo (estudio de fraude en transacciones):
- Variable dependiente: `es_fraude` (sí/no).
- Variables independientes: `monto`, `canal`, `tienda`, `cliente`, `fecha_hora`.
- Variables derivadas: `hora_del_dia`, `dia_semana`, `monto_promedio_ultimo_mes`.

Grupos de información
- `clientes` (información personal)
- `tiendas` (información comercial)
- `transacciones` (cada compra)

¿Cómo se relacionan?
- Un cliente puede hacer muchas transacciones
- Una tienda puede recibir muchas transacciones
- Cada transacción pertenece a un cliente y una tienda

¿Una tabla o múltiples tablas?

La respuesta depende de tu **unidad de observación** y de cómo llegaron los datos:

Modelo relacional (múltiples tablas)

- Datos provenientes de sistemas diferentes
- Hay relaciones de muchos-a-muchos
- *Ejemplo siguiente*: clientes + tiendas + transacciones

Formato plano (una sola tabla)

- Cada fila es una observación completa
- Encuestas, sensores o registros de una sola fuente
- Dataset ya integrado desde el origen
- La mayoría de repositorios públicos y Kaggle

Important

Independientemente del formato de origen, la mayor parte del análisis estadístico requiere una sola tabla *lista para analizar*. Si partes de múltiples tablas, eventualmente las integrarás en una para el análisis.

Esquema simple de organización

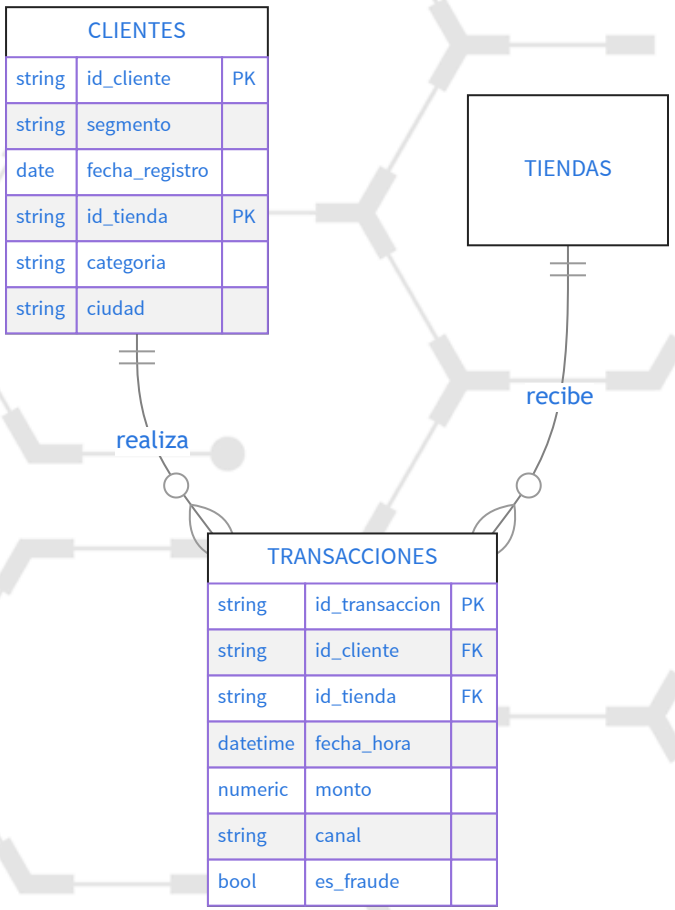

Ejemplo práctico — Estructura en SQL

```sql
-- Tabla principal de transacciones
CREATE TABLE transacciones (
  id_transaccion TEXT PRIMARY KEY,
  id_cliente TEXT NOT NULL,
  id_tienda TEXT NOT NULL,
  fecha_hora TIMESTAMP NOT NULL,
  monto DECIMAL(10,2) CHECK (monto >= 0),
  canal TEXT CHECK (canal IN ('pos','web','app','telefono')),
  es_fraude BOOLEAN NOT NULL DEFAULT 0
);

-- Tabla de clientes
CREATE TABLE clientes (
  id_cliente TEXT PRIMARY KEY,
  segmento TEXT,
  fecha_registro DATE
);

-- Tabla de tiendas
CREATE TABLE tiendas (
  id_tienda TEXT PRIMARY KEY,
  categoria TEXT,
```

> Este es solo un ejemplo. Adáptalo a tu proyecto específico.

Conceptos clave para organizar datos

- **Identificadores únicos**: cada fila en una tabla debe tener un código único.
- **Referencias entre tablas**: usar códigos para conectar información relacionada.
- **Tipos de datos apropiados**: números para cantidades, texto para nombres, fechas para tiempo.
- **Reglas de validación**: establecer qué valores son aceptables.

Reglas básicas

- Cada tabla debe tener un identificador único principal.
- Usar códigos simples para conectar tablas (no texto largo).
- Mantener los identificadores estables (no cambiarlos después).

Diccionario de datos - ¿qué es cada variable?

Tabla	Variable	Tipo	Valores permitidos	¿Puede estar vacío?	Descripción	De dónde viene
transacciones	id_transaccion	Texto	Código único	No	Identificador de cada compra	Sistema
transacciones	monto	Número	Mayor a 0	No	Cantidad en pesos	Terminal
transacciones	fecha_hora	Fecha	Formato YYYY-MM-DD	No	Cuándo ocurrió	Sistema
transacciones	es_fraude	Sí/No	Verdadero o Falso	No	¿Es fraudulenta?	Analista

> Mantén este archivo actualizado y guárdalo como `diccionario_datos.csv`. Agrega una columna **"Transformación aplicada"** si imputas o agregas alguna variable.

Ruta metodológica y diseño de datos

Elemento	Pregunta central	Resultado esperado
Pregunta de investigación	¿Qué quiero responder?	Delimita el fenómeno de estudio
Unidad de análisis	¿Cuál es mi fila?	Define la estructura de la tabla
Variables clave	¿Qué observar o medir?	Lista de columnas necesarias
Fuente de datos	¿De dónde provienen?	Identifica proveedores y métodos
Formato de almacenamiento	¿Una tabla o varias?	Esquema de organización
Pipeline de preparación	¿Qué transformar?	Limpieza, imputación, agregación

Tip

Antes de recolectar un solo dato, completa esta tabla. Cada fila debe tener una respuesta documentada en tu protocolo de investigación.

¿De dónde obtengo mis datos?

¿Qué datos necesito?

- Identifica todas las variables en tu diccionario.
- Asegúrate que cada variable tenga una fuente definida.
- Determina la frecuencia de recolección necesaria.

Métodos de recolección

- **Fuentes directas**: encuestas que yo diseño, experimentos, observaciones.
- **Fuentes existentes**: bases de datos públicas, APIs, archivos institucionales.
- **Herramientas de captura**: formularios digitales, sensores, programas de descarga automática.

Planificación del muestreo

Evaluación del origen de los datos

Antes de analizar, responde estas 6 preguntas de control:

Dimensión	Preguntas clave
Procedencia	¿De dónde provienen los datos? ¿Quién los generó? ¿Son propios o de terceros?
Generación/recolección	¿Cómo se recolectaron? ¿Bajo qué condiciones? ¿Existe protocolo?
Estructura y alcance	¿Cuál es la unidad de observación? ¿Qué periodo cubren? ¿Qué cobertura geográfica/poblacional tienen?
Calidad y confiabilidad	¿Se validaron? ¿Hay faltantes, sesgos o errores conocidos? ¿Son consistentes entre periodos/fuentes?
Transformaciones previas	¿Son datos crudos o procesados? ¿Qué agregaciones/imputaciones se aplicaron? ¿Se integraron múltiples fuentes?
Restricciones y uso	¿Hay límites legales, éticos o de licencia? ¿El propósito original es compatible con tu proyecto?

Tip

Versión compacta: Procedencia · Generación · Estructura · Calidad · Transformaciones · Restricciones. Documenta respuestas breves en tu `README.md` o protocolo.

Important

Si no puedes responder con evidencia documental estas 6 dimensiones, tu base aún no está lista para análisis inferencial.

Control de calidad de los datos

> La evaluación del origen responde *qué preguntar* antes de recolectar; el control de calidad responde *cómo verificar* lo que ya tienes.

Prevención (al momento de capturar)

- Usar formularios que validen automáticamente los datos.
- Crear listas de opciones cerradas cuando sea posible.

Detección de errores (después de capturar)

- Verificar que no hay duplicados donde no debería haberlos.
- Revisar que los valores estén en rangos razonables.
- Comprobar que las fechas sean lógicas.

Documentación

- Registrar de dónde viene cada dato y cuándo se capturó.
- Mantener los datos originales sin modificar en una carpeta separada.

De datos crudos a datos listos para análisis

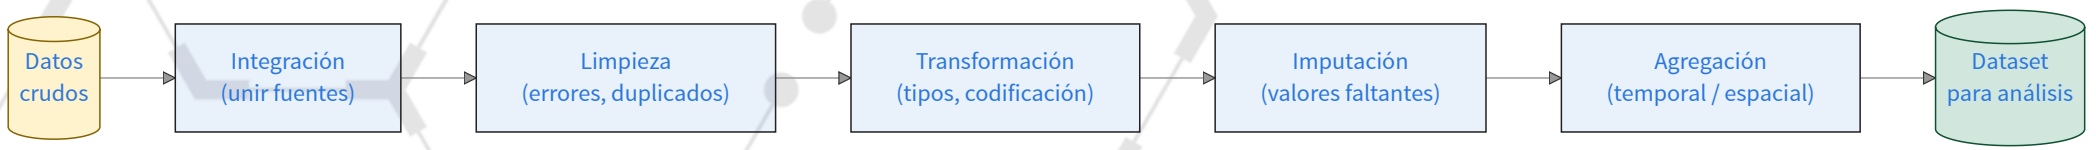

> No todos los proyectos requieren todos los pasos ni en este orden. Documenta cada transformación que apliques.

Agregación: resumir datos por grupos

Cuando tienes observaciones individuales que necesitas resumir por período o región:

Agregación temporal — de registros diarios a resumen mensual:

Fecha	Monto	→	Mes	Total	Promedio
2024-01-03	450		2024-01	12 300	410
2024-01-07	380		2024-02	14 500	483
2024-01-15	520				

Agregación espacial — de municipio a estado:

Municipio	Índice	→	Estado	Media	N
Zapopan	8.2		Jalisco	7.9	125
Tlaquepaque	7.6				

Tip

La granularidad adecuada depende de tu **pregunta de investigación**. Elige el nivel que responda lo que quieres saber, no el que sea más fácil de obtener.

Imputación: qué hacer con datos faltantes

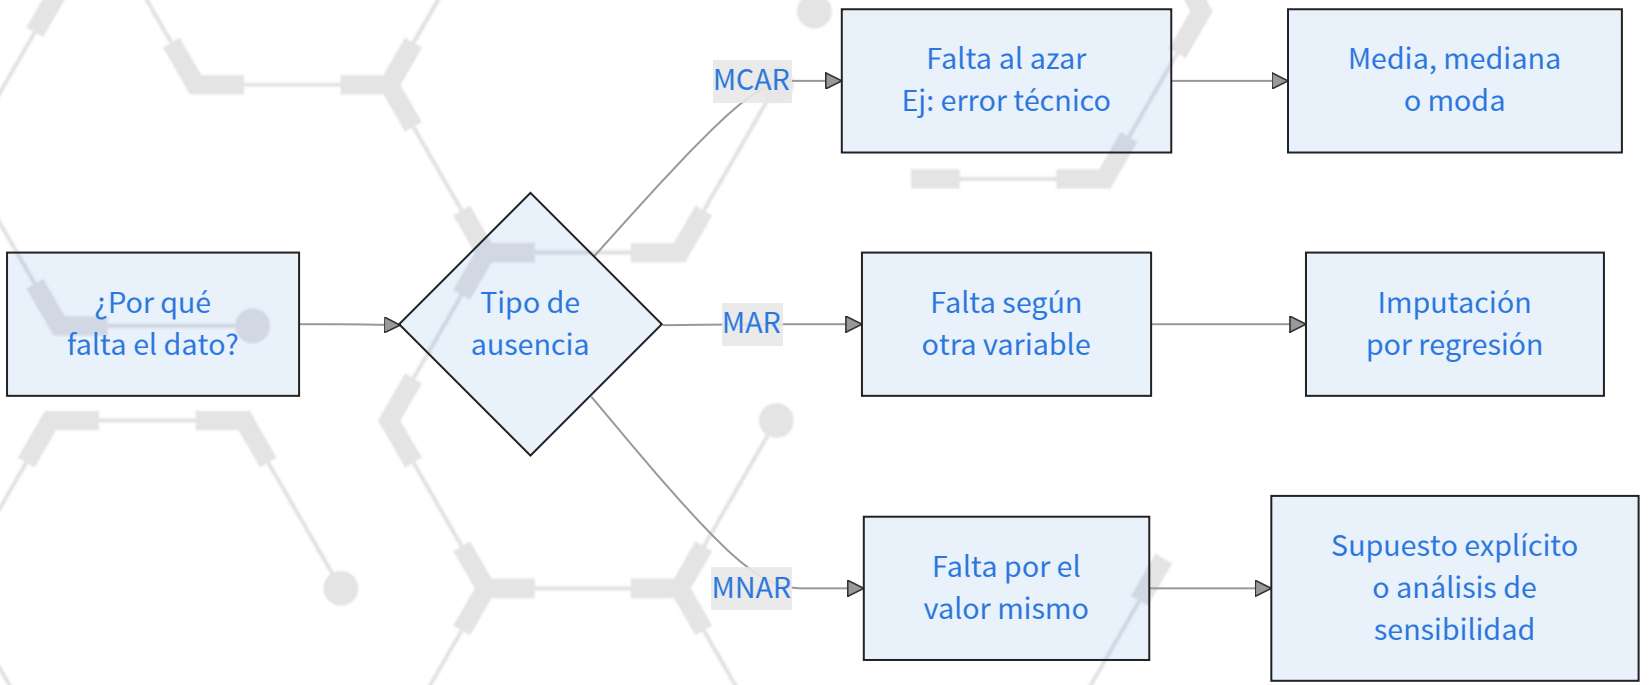

> Identificar el mecanismo de ausencia es el primer paso antes de elegir cualquier método (Little & Rubin, 2002; Rubin, 1976).

Métodos de imputación comunes

Método	Cuándo usarlo	Ventaja	Limitación
Eliminar filas	Pocos faltantes (<5%), MCAR	Simple	Pierde información
Media / mediana	Numéricas, MCAR	Rápido	Subestima la varianza
Moda	Categóricas	Fácil	Sesgo si hay dominancia
Valor anterior (fill)	Series de tiempo	Respeta la tendencia	Solo datos ordenados
Regresión	MAR, variables correlacionadas	Preciso	Requiere más trabajo
Imputación múltiple	Análisis formales	Estadísticamente robusto	Complejo de implementar

⚠ **Warning**

Documenta siempre qué método usaste y en qué variables. El método elegido debe justificarse en tu sección de metodología.

> Para imputación múltiple se recomienda consultar Buuren (2018) (disponible en línea), Sterne et al. (2009) y la implementación en R de Buuren & Groothuis-Oudshoorn (2011). Schafer & Graham (2002) ofrece una revisión metodológica accesible.

Consideraciones éticas y de privacidad

- **Minimiza la recolección**: solo recolecta los datos que realmente necesitas.
- **Protege la identidad**: usa códigos en lugar de nombres cuando sea posible.
- **Controla el acceso**: define quién puede ver qué información.
- **Datos sintéticos**: si necesitas compartir datos, considera generar versiones artificiales que mantengan las características importantes pero no revelen información personal.

¿Qué son los datos sintéticos?

Los **datos sintéticos** son conjuntos de datos artificiales que imitan las características estadísticas de datos reales sin contener información real de personas específicas.

¿Cuándo usarlos?

- Para compartir datos con colaboradores
- Para publicar datasets de investigación
- Para entrenar modelos sin exponer datos sensibles
- Para crear ejemplos educativos

Ventajas

- Protegen la privacidad individual
- Mantienen patrones estadísticos útiles
- Permiten reproducibilidad
- Eliminan restricciones legales de uso

Ejemplo práctico: Dataset de estudiantes

Datos originales (sensibles):

ID	Nombre	Edad	Promedio	Ciudad
1	María García	22	8.5	Guadalajara
2	Juan López	24	7.2	Monterrey

Datos sintéticos (seguros para compartir):

ID	Edad	Promedio	Ciudad
1	23	8.3	Ciudad_A
2	25	7.0	Ciudad_B

> Los datos sintéticos mantienen las relaciones entre edad y promedio, pero eliminan nombres reales y codifican ubicaciones.

Herramientas básicas:

Organización de archivos para tu proyecto

```
/datos
  /originales       # datos tal como los obtuviste (no tocar)
  /procesados       # datos limpios listos para análisis
  diccionario_datos.csv
/documentos
  esquema_datos.png # tu diagrama de organización
README.md          # explicación del proyecto
```

Herramientas recomendadas

- **Excel/Google Sheets**: para empezar y datos pequeños.
- **SQLite**: base de datos simple, ideal para aprender.
- **R/Python**: para análisis más avanzados.
- **Google Forms**: para recolectar datos con formularios.

> Elige la herramienta según el tamaño de tus datos y tu experiencia.

Lista de verificación para la Evidencia 4A

Actividad

1. **Decide** si tu proyecto requiere una tabla o varias, y justifica la respuesta.
2. **Construye** una mini matriz de coherencia: pregunta específica → objetivo → hipótesis → variable/métrica.
3. **Dibuja** tu pipeline: ¿qué pasos debes aplicar desde los datos crudos hasta el dataset listo para análisis?
4. **Define** los campos principales (8-10 variables clave) e indica si alguna requiere imputación, agregación o derivación.
5. **Aplica** el checklist de evaluación del origen de datos y registra una evidencia por cada dimensión.
6. **Escribe** 3 posibles problemas de calidad y cómo los resolverías (duplicados, valores faltantes, valores fuera de rango).
7. **Describe** tu plan de recolección: fuente, granularidad temporal/espacial y frecuencia.

Puntos clave para recordar

- **Planifica antes de recolectar**: diseña tu estructura de datos antes de empezar a capturar información.
- **Documenta todo**: mantén un diccionario actualizado de qué significa cada variable y qué transformaciones se le aplicaron.
- **Prepara, no solo recolecta**: casi siempre necesitarás limpiar, imputar o agregar antes de analizar.
- **Elige la granularidad correcta**: la unidad de análisis (fila) debe corresponder con tu pregunta de investigación.
- **Considera la ética**: protege la privacidad y recolecta solo lo necesario.

Referencias

Buuren, S. van. (2018). *Flexible imputation of missing data* (2nd ed.). CRC Press / Chapman & Hall. https://stefvanbuuren.name/fimd/

Buuren, S. van, & Groothuis-Oudshoorn, K. (2011). Mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, *45*(3), 1–67. https://doi.org/10.18637/jss.v045.i03

Little, R. J. A., & Rubin, D. B. (2002). *Statistical analysis with missing data* (2nd ed.). John Wiley & Sons.

Rubin, D. B. (1976). Inference and missing data. *Biometrika*, *63*(3), 581–592. https://doi.org/10.1093/biomet/63.3.581

Schafer, J. L., & Graham, J. W. (2002). Missing data: Our view of the state of the art. *Psychological Methods*, *7*(2), 147–177. https://doi.org/10.1037/1082-989X.7.2.147

Sterne, J. A. C., White, I. R., Carlin, J. B., Spratt, M., Royston, P., Kenward, M. G., Wood, A. M., & Carpenter, J. R. (2009). Multiple imputation for missing data in epidemiological and clinical research: Potential and pitfalls. *BMJ*, *338*, b2393. https://doi.org/10.1136/bmj.b2393

Recursos adicionales (1/2)

Aprendizaje de SQL y bases de datos

- **SQL Bolt** - Tutorial interactivo de SQL: https://sqlbolt.com/
- **W3Schools SQL** - Tutorial básico de SQL: https://www.w3schools.com/sql/
- **DB Browser for SQLite** - Herramienta visual para SQLite: https://sqlitebrowser.org/
- **Kaggle Learn** - Cursos gratuitos de bases de datos: https://www.kaggle.com/learn

Herramientas para recolección de datos

- **Google Forms** - Para crear formularios de captura: https://forms.google.com/
- **Microsoft Forms** - Alternativa a Google Forms: https://forms.microsoft.com/
- **SurveyMonkey** - Para encuestas más complejas: https://www.surveymonkey.com/

Tip

Recursos adicionales (2/2)

Datos sintéticos y privacidad

- **Faker (Python)** - Librería para generar datos sintéticos: https://faker.readthedocs.io/
- **Synthpop (R)** - Paquete para datos sintéticos: https://cran.r-project.org/package=synthpop
- **SDV** - Synthetic Data Vault: https://sdv.dev/
- **Mostly AI** - Plataforma de datos sintéticos: https://mostly.ai/

Ética y buenas prácticas

- **FAIR Data Principles** - Principios para datos FAIR: https://www.go-fair.org/fair-principles/
- **Guía de ética en datos del MIT**: https://ethics.fast.ai/

> **Note**
>
> **Recursos avanzados**: Estos recursos son útiles cuando ya tengas experiencia básica y necesites proteger datos sensibles o